

课程作业：探索 Structure from Motion 与相机位姿估计技术

概述

本次作业围绕 Structure from Motion (SfM) 和相机位姿估计展开，共四道题目。

- ❖ 前两题题目为基础题，要求在简单的静态场景视频上完成 SfM 并进行实验分析；
- ❖ 后两题题目为开放性题目，分别探讨复杂动态场景下 SfM 面临的挑战，以及相机位姿质量的自动化评估。

最终提交内容：每道题目的代码（含描述如何运行代码的 README）+ 报告（PDF）。不建议在报告中堆字数，最终作业评分不会与报告字数多少直接相关。

格式约定：本作业中所有位姿数据均采用 COLMAP 的 sparse reconstruction 格式，位姿使用 .txt 存储，不使用 .bin 压缩。

具体的，对于题目一到题目三的视频的 SfM 结果，均应按以下目录组织：

结果

```
|---- images/
    |---- xxxxx.jpg 从视频中抽出的用于 SfM 的帧
    |---- 为节省空间，可不在此目录存储图片，但需在报告中说明抽取了哪些帧，如何命名
|---- sparse/
    |---- 0/
        |---- images.txt
        |---- cameras.txt
        |---- points3D.txt
```

每个文件内容的定义可参阅 <https://colmap.github.io/legacy/3.10/format.html> 理解。

其中，points3D.txt 可为空文件，images.txt 里存储点云 POINTS2D[] 的行可留空。

所有用到的视频数据、位姿文件见附件。

提示：COLMAP sparse reconstruction (SfM) 在视频上运行耗时较长（参考附录），请合理规划时间，尽早开始实验或初步尝试。

题目一：静态场景的 SfM（25 分）

任务描述

在该题目中，你将探索最简单的静态场景视频的 SfM 三维重建。我们提供了三段静态场景视频 S1-1.mp4, S1-2.mp4, S1-3.mp4。

请对全部三段视频完成以下流程：

- 1) **（可能需要）视频抽帧。**从视频中提取图像帧用于后续处理。你需要自行决定抽帧间隔和总帧数，并在报告中说明选择依据。提示：抽帧过密会显著增加计算时间，过疏则可能导致相邻帧之间的视觉重叠不足、特征匹配失败。
- 2) **运行 SfM。**使用 SfM 工具进行稀疏重建，得到每帧的相机位姿。课上已介绍的 COLMAP 是一个合适的选择，其稀疏重建阶段可以在 CPU 上完成。你只需运行到 sparse reconstruction 阶段，不需要运行 Multi-View Stereo (MVS)。当然，你也可以使用其他 SfM 工具。
- 3) **可视化相机轨迹。**将估计得到的相机位姿可视化为三维空间中的轨迹。最基本的做法是提取每帧的相机中心并绘制为三维折线图。

报告要求

在报告中描述你的完整流程（工具选择、关键参数、抽帧策略），展示三段视频的相机轨迹可视化结果，并简要对比三种场景下的重建情况（如成功注册的帧数比例、轨迹形状是否符合自己观看完视频后的直觉等）。

评价参考

- ❖ 良好：成功运行 SfM 并展示了合理的轨迹可视化。
- ❖ 优秀：完成至少一项额外任务：
 - 讨论视频抽帧策略对精度和效率（处理时间等）的影响；
 - 或对三种场景做有意义的对比分析；
 - 或进行额外的深入分析，例如尝试不同参数或特征类型的对比实验等。

题目二：SfM 结果的子序列分析（25 分）

任务描述

对于题目一中的 S1-2.mp4，从完整帧序列中自行设计并截取三段不同的连续子序列（建议在起止位置和长度上有所变化，例如前 1/3、中间 1/2 或后 1/4 等）。请对截取出的子序列完成以下流程：

1) 用以下两种方式获取该子序列的相机位姿：

- ❖ 对题目一中产生的该视频的 SfM 结果，截取该子序列对应的帧的位姿。
- ❖ 仅使用该子序列对应的抽帧，从头运行一次 SfM，得到新的位姿估计。

2) 对比两种方法的结果。

其中的关键问题在坐标系对齐。SfM 的输出位姿处于一个任意的相似变换下，尺度、旋转、平移均是不确定的。方法 A 的位姿继承了完整重建的坐标系，方法 B 的位姿则在一个全新的坐标系中。因此两组位姿不能直接逐帧比较。

你需要先对两组位姿进行坐标系对齐。一个参考做法是通过 Procrustes analysis 求解一个最优的 Sim(3) 变换（7 自由度：1 尺度 + 3 旋转 + 3 平移），将方法 B 的位姿变换到方法 A 的坐标系下。

对齐后，可以通过可视化两条轨迹的叠加图以及计算 ATE（Absolute Trajectory Error）等定量指标来评估差异。

报告要求

描述你的实验设计和对齐方法，展示定性（可视化）和定量（ATE 等）的对比结果。

重点在于分析：在什么条件下两种方法的差异较大，什么条件下差异较小？为什么？可从 Bundle Adjustment (BA) 的全局优化特性、loop closure 提供的约束、以及观测数量对重建精度的影响等角度进行讨论。

评价参考

- ❖ 合格：对于三段子序列，完成两种方式的位姿获取并展示结果。
- ❖ 良好：正确实现坐标系对齐算法，给出了定量比较，报告中有相关的合理分析。
- ❖ 优秀：探索多种截取条件，对 loop closure 和全局 BA 的影响给出深入分析。

题目三：动态场景下的 SfM（25 分，开放题）

任务描述

现实视频中常包含动态物体（如行人、车辆）。传统 SfM 基于"静态场景"假设：所有特征点在三维空间中固定不动。动态物体违反了这一假设，由其产生的特征匹配会误导位姿估计和三角化，可能导致重建质量严重下降甚至完全失败。

我们提供两段包含显著动态物体（行人，车辆等）的视频 S2-1.mp4，S2-2.mp4。请对这两段视频完成以下流程：

1) **观察与分析**。对提供的动态视频直接运行 SfM（与题目一相同），记录结果：

- ❖ SfM 是否成功？
- ❖ 如果结果不理想，具体表现是什么？
- ❖ 是注册帧数大幅减少？轨迹出现不合理的跳变？稀疏点云混乱？

请在报告中分析失败的原因。

2) **改进方案**。探索一种方法来改善动态场景下的 SfM 效果。你可以自由查阅文献、探索任何你认为合理的途径。实现后，展示改进前后的效果对比。

以下是一些可能的方向，仅供参考：

- ❖ 如果能在特征提取或匹配阶段排除属于动态物体的特征点，SfM 的鲁棒性可能会提高。
- ❖ COLMAP 可能支持输入 `image mask` 来屏蔽指定区域的特征检测。
<https://colmap.github.io/legacy/3.10/faq.html#mask-image-regions>
- ❖ 动态区域的检测可以通过多种方式实现，例如语义分割模型等。

报告要求

描述直接运行 SfM 时观察到的现象和你的分析，阐述改进方案的思路 and 实现细节，展示改进前后的效果对比。

评价参考

- ❖ 合格：对两段视频完成最原版的 SfM 实验，合理分析失败原因。
- ❖ 良好：提出改进思路，测试一种改进方案，展示其在两段视频上的改进效果。
- ❖ 优秀：在至少一个视频上对比三种及以上的方案的优劣势，或对一种改进方案做深入分析或优化。

题目四：相机位姿质量评估（25 分，开放题）

任务描述

在实际应用中，我们经常需要判断位姿估计方法输出的结果是否可靠。然而，对于真实采集的视频，我们通常没有精确的 `ground truth` 位姿（获取 `ground truth` 本身就需要昂贵的设备或繁琐的标定流程）。因此，如何在缺乏 `ground truth` 的情况下评估位姿质量，是一个具有实际意义的问题。

我们提供在工业界生产中发现的 10 个特别的视频和对应的位姿数据（均为 COLMAP txt 格式）。其中部分位姿质量较好（后五个 06 ~ 10, good），部分存在明显的局部误差（前五个 01 ~ 05, bad，即某些局部帧的位姿偏离真实值较远）。我们同时为每组数据提供一个 good/bad 标注作为验证依据。

请完成以下任务：

- 1) **设计评估指标**。提出至少一种不依赖 `ground truth` 的位姿质量检验方法，在报告中说明该方法的原理和直觉。
- 2) **实现自动评估**。选择一种指标，编写代码对 10 组位姿分别计算质量分数。
- 3) **验证有效性**。用我们提供的 good/bad 标注来检验你的评估结果：你的质量分数是否能有效区分 good case 和 bad case？可以将此视为一个二分类问题来衡量。

以下是一些可能的方向，仅供参考：

- ❖ 相邻帧位姿变化的平滑性是否合理（有无突变、瞬移）；
- ❖ 给定两帧位姿后，匹配特征点是否满足对极几何约束（如计算点到极线的距离）；
- ❖ 通过位姿三角化得到的 3D 点重投影回图像时的误差大小；
- ❖ 多帧位姿之间的组合一致性，即 T_{ik} 是否近似于 $T_{ij} \cdot T_{jk}$ 。

报告要求

描述你提出的评估指标及其原理，展示在 10 组数据上的评估结果（建议用图表呈现），分析你的指标在区分 good/bad 上的表现，讨论其优点和局限。

评价参考

本题为开放性题目，重视你的思考过程或实验努力。算法准确度不直接作为评价指标。

- ❖ 合格：提出一种合理的评估思路并给出清晰的分析。
- ❖ 良好：实现一种方法，在给定的数据上给出评估结果，并展示合理的区分能力。
- ❖ 优秀：实现多种方法并做了对比，或设计综合评估指标，或在分析中展现深入的洞察。

附录

一、 素材详细参数

在 `./assets/` 目录下，我们提供实验所需素材。具体的：

视频名称	参数	时长	帧数量
<code>./assets/videos/S1-1.mp4</code>	H.264, 960x720, 30FPS	45s	1362
<code>./assets/videos/S1-2.mp4</code>	H.264, 960x720, 30FPS	79s	2070
<code>./assets/videos/S1-3.mp4</code>	H.264, 1280x720, 30FPS	25s	750
<code>./assets/videos/S2-1.mp4</code>	H.264, 1137x640, 30FPS	20s	600
<code>./assets/videos/S2-2.mp4</code>	H.264, 1138x640, 30FPS	20s	600

对第四题，`./assets/annotations/` 下存储了 10 个视频 `video.mp4` 和对应的位姿数据 `sparse/0`。其中 01 ~ 05 为 bad case, 06 ~ 10 为 good case。重建结果为 30FPS 结果，但原始视频可能为 30/60FPS，分析时可能需要对视频做帧率转换。

二、 用时参考

为防止对实验用时预估有误，造成实验无法按时完成，现统计一参考情况实验用时，结果如下，供参考：

测试平台：荣耀 MagicBook14 2022 锐龙版

- ❖ CPU: AMD Ryzen R5-6600H, 6C12T @ 4.0GHz
- ❖ Memory: 16GB, DDR5 @ 6400 MT/s
- ❖ COLMAP 版本: 4.0.3 Windows No-CUDA
- ❖ 使用 GPU 加速（观察到 COLMAP 调用了 CPU 自带的 AMD 核显，占用率可达约 90%）

使用 COLMAP 做 feature extraction, feature matching, mapping, 对 S1-2.mp4 做全量 2070 帧（无抽帧）的处理。具体的：

- ❖ extraction 使用 PINHOLE model, shared for all images, 其他参数默认；
- ❖ matching 方式改为 sequential matching, 其他参数默认；
- ❖ mapper 改为 hierarchical mapper, 其他参数默认

各环节用时如下：

- ❖ Feature Extraction. 1.711 min
- ❖ Matching. 2.295 min
- ❖ Mapping. 10min 注册约 250 帧，全部完成预计至少为 4h

若确实时间有限无法完成全部实验，建议考虑更激进的抽帧策略（例如每秒仅抽 5 帧）；或，对于第一题、第三题，高质量地完成仅一个视频的 SfM 重建结果也可接受。若有特殊情况，请及时联系老师。